

支持向量机的原理

分享人：张召凯



问题

1


如何用支持向量机将一组正负样本分离

2

支持向量机和深度学习的关系

目录

CONTENTS



1

线性可分支持向量机

2


线性支持向量机

线性可分支持向量机定义：

训练数据线性可分时，通过**硬间隔最大化**，学习到的线性分类器。

考虑右图二维特征空间中的分类问题

- ★ 代表正样本
- 代表负样本



A表示一个距离超平面最近的样本，距离为d，最大化d。

可以表示为下面约束最优化问题

$$\begin{array}{ll} \max_{w,b} & d \\ \text{s.t.} & d_i \geq d, \quad i = 1, 2, \dots, N \end{array}$$

解上述最优化问题，我们需要引入三个概念

点到平面的距离公式

点 x_0 到超平面 $w x + b = 0$ 的距离公式

$$d = \frac{|w x_0 + b|}{\|w\|}$$

几何间隔

几何间隔表示为 γ , 则样本点 (x_i, y_i) 的几何间隔为

$$\gamma_i = \frac{y_i(w x_i + b)}{\|w\|}$$

函数间隔

函数间隔表示为 $\hat{\gamma}$, 则样本点 (x_i, y_i) 的几何间隔为


$$\hat{\gamma}_i = y_i(w x_i + b)$$

假定超平面为 $wx+b=0$ ，那距离为 d 到底是多少？

我们假定间隔边界所在的平面为 $wx+b= \pm a$ ，而A样本点位于边界之上，我们称之为支持向量。

d 可以表示为

$$d = \frac{a}{\|w\|}$$



约束最优化问题可以转化成下述问题

$$\begin{aligned} & \max_{w,b} \frac{a}{\|w\|} \\ \text{s.t.} \quad & \frac{y_i(wx_i + b)}{\|w\|} \geq \frac{a}{\|w\|}, i = 1, 2, \dots, N \end{aligned}$$

为什么a可以用1代替

最常见的线性可分支持向量机的形式

$$\begin{aligned} & \max_{w,b} \frac{1}{\|w\|} \\ \text{s.t.} \quad & y_i(wx_i + b) \geq 1, i = 1, 2, \dots, N \end{aligned}$$

对于任意的函数间隔 $\pm a$, 在 x 不变的情况的下, 我们都可以找到一个因子 λ , 使得函数间隔变为 1, 即 $\lambda wx + \lambda b = 1$

对于我们最终想要的超平面 $wx + b = 0$ 来说, 如果得到 $\lambda wx + \lambda b = 0$ 的话, 是一样的。

在变换前后, 支持向量不变, 支持向量到超平面的距离也不变。

目标函数的替换

$$\begin{aligned} & \max_{w,b} \quad \frac{1}{\|w\|} \\ \text{s.t.} \quad & y_i(wx_i + b) \geq 1, i = 1, 2, \dots, N \end{aligned}$$



$$\begin{aligned} & \min_{w,b} \quad \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & y_i(wx_i + b) \geq 1, i = 1, 2, \dots, N \end{aligned}$$

这个替换和我们本科是用拉格朗日条件极值解题做的替换一样——方便计算

构造拉格朗日函数

$$L(w, b, \alpha) = \frac{\|w\|^2}{2} - \sum_{i=1}^N \alpha_i y_i \{(w \cdot x_i + b) - 1\}$$

$$s.t. \quad \alpha_i \geq 0$$

$$y_i(w \cdot x_i + b) - 1 \geq 0 \quad i = 1, 2, \dots, N$$

上式中第二项恒大于等于零，所以上述函数的最大值存在的情况下，就为第一项的值

优化问题转化为

$$\min_{\alpha} \max_{w, b} L(w, b, \alpha)$$

L是凸函数，属于凸函数优化问题。

此处的凸函数定义与同济高数书上的定义是反的

拉格朗日对偶问题

$$\min_{\alpha} \max_{w,b} L(w, b, \alpha)$$



$$\max_{\alpha} \min_{w,b} L(w, b, \alpha)$$

当 w, α 满足KKT条件时, 原始问题的解和对偶问题的解相同

$$\begin{aligned} \nabla_w L(w^*, b^*, \alpha^*) &= 0 \\ \nabla_b L(w^*, b^*, \alpha^*) &= 0 \\ \alpha^* (y_i (w^* \cdot x_i + b^*) - 1) &= 0 \\ y_i (w^* \cdot x_i + b^*) - 1 &\geq 0 \\ \alpha^* &\geq 0 \quad i = 1, 2, \dots, N \end{aligned}$$

对变量 w, b, α 求偏导, 并令偏导为0可得:

$$\omega = \sum_{i=1}^m \alpha_i y_i x_i$$

$$\sum_{i=1}^m \alpha_i y_i = 0$$

将结果代入

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0 \quad i = 1, 2, \dots, N$$

根据KKT条件，可以得到原始最优化问题的解

$$w^* = \sum_{i=1}^N \alpha_i y_i x_i$$


$$b^* = y_j - \sum_{i=1}^N \alpha_i y_i (x_i \cdot x_j)$$

(x_j, y_j) 是 α_j 不为0的样本

分类决策函数

$$f(x) = \text{sgn}\left(\sum_{j=1}^N \alpha_j y_j (x_j \cdot x) + b^*\right)$$

如下图所示训练集，正样本点 $(1, 0)$ ，负样本点 $(2, 0)$ ，试求最大间隔分离超平面。




线性支持向量机定义：

在训练数据线性不可分时，通过软间隔最大化，学习到的线性分类器。

考虑右图二维特征空间中的分类问题

- ★ 代表正样本
- 代表负样本



A表示一个距离超平面最近的样本，距离为 d ，最大化 d 的同时，最小化 ξ 。

约束最优化问题

$$\begin{aligned} & \min \frac{\|w\|^2}{2} + C\xi_i \\ \text{s.t.} \quad & y_i(wx_i + b) \geq 1 - \xi_i \quad i = 1, 2, \dots, N \\ & \xi_i \geq 0 \quad i = 1, 2, \dots, N \end{aligned}$$

松弛变量 ξ :

惩罚参数 C :

最小化目标函数的两层含义:

- 1、间隔尽量大
- 2、误分类点的个数尽量小

构造拉格朗日函数

$$L(w, b, \alpha, \mu) = \frac{\|w\|^2}{2} - \sum_{i=1}^N \alpha_i \{y_i(w \cdot x_i + b) - 1 + \xi_i\} - \sum_{i=1}^N \mu_i \xi_i$$

$$s.t. \quad \alpha_i \geq 0 \quad \mu_i \geq 0 \quad i = 1, 2, \dots, N$$

转化为拉格朗日对偶问题，分别对 w, b, α, μ 求偏导，并令偏导数为0，得

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$C - \alpha_i - \mu_i = 0$$

$$\alpha_i \geq 0$$

$$\mu_i \geq 0 \quad i = 1, 2, \dots, N$$

消去 μ

$$\begin{aligned} \max_{\alpha} \quad & -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C \quad i = 1, 2, \dots, N \end{aligned}$$

形式上和线性可分支持向量机差不多，只是求 \mathbf{b} 时，需要选取 $0 < \alpha < C$ 对应的样本进行计算

支持向量

线性可分支持向量机

- 间隔边界上的向量

线性支持向量机

- 间隔边界上的向量 ($0 < \alpha < C$, 此时 $\xi = 0$, μ 为任意值)
- 间隔边界与超平面之间的向量 ($\alpha = C$, 此时 $\mu = 0$, $0 < \xi < 1$)
- 超平面上的向量 ($\alpha = C$, 此时 $\mu = 0$, $\xi = 1$)
- 分离超平面误分类的向量 ($\alpha = C$, 此时 $\mu = 0$, $\xi > 1$)

线性支持向量机的另一种形式

$$\min_{w,b} \sum_{i=1}^N [1 - y_i(w \cdot x_i + b)]_+ + \lambda \|w\|^2$$

合页损失函数(hinge loss function)

$$L(y(wx + b)) = [1 - y(wx + b)]_+$$


取正值函数

$$[z]_+ = \begin{cases} z, & z > 0 \\ 0, & z \leq 0 \end{cases}$$

$$\begin{aligned} & \min \frac{\|w\|^2}{2} + C\xi_i \\ \text{s.t.} \quad & y_i(wx_i + b) \geq 1 - \xi_i \quad i = 1, 2, \dots, N \\ & \xi_i \geq 0 \quad i = 1, 2, \dots, N \end{aligned}$$



合页损失函数的应用



① 为线性支持向量机的损失函数

② 为感知机的损失函数

	线性可分支持向量机	线性支持向量机	深度学习
是否有损失	无	有	有
损失函数	无	合页损失函数+L2正则化	最小均方差
学习方法	凸二次规划	凸二次规划	梯度下降
适用范围	线性可分	近似线性可分	线性和非线性都适用
数据集数量依赖	低	低	高

参考

- 1、统计学习方法-李航
- 2、<https://www.cnblogs.com/xxrxxr/p/7536131.html>
- 3、<https://www.jianshu.com/p/fe14cd066077>

感谢

贾鑫康推荐编写数学公式的工具

Vscode+ Markdown All in One (plugin)

谢谢

